

公開自動運転動画に対する視覚言語モデルを用いた 時系列シーンラベリングの品質・計算費用評価

Quality and Computational Cost of Temporal Scene Labeling with a Vision-Language Model on Public Driving Videos

Ryota Yamada

Amazon Web Services, Inc.

概要

自動運転走行データのラベリングは、学習データの分布把握、希少事象の検索、hard-negative mining、および active learning における人手確認対象の選定に必要である。一方、既存の大規模走行データでは負例が網羅的に確認されていない場合があり、Precision や Accuracy を含む定量評価が成立しない。本稿では、密な時間注釈を持つ公開 ROAD dataset を用い、8 秒 clip に対する 13 タグの完全な正負 Ground Truth を構成した。元動画単位で development/evaluation を分離し、Cosmos 3 Nano および Super について、frame sampling、timestamp 明示、prompt 形式、grouped request、multimodal/prefix cache が品質、tail latency、stage 時間および GPU 費用へ与える影響を評価した。同一 ROAD clips を用いる controlled serving experiment により、continuous batching、Chunked Prefill および cache 再利用の効果を、入力内容と prompt を固定して分離した。方式探索は class-balanced Smoke、方式固定は development、最終性能推定は evaluation へ分け、複雑な候補は単純 baseline を上回った場合だけ次段階へ進めた。Evaluation で母集団性能まで確認した構成は、timestamp 付き 24-frame evidence、Super、および固定 VO prior である。これに対し、タグ限定 Hybrid Core Reasoning は development で選定し、候補駆動 48-frame Recall pass は GT を用いた難例診断で上限を調べた。従って後二者は提案系の extension であるが、Evaluation 性能へ数値合成しない。evaluation は 875 clips、15 source videos、11,314 known clip-tag pairs を含む。最良条件 Super / 固定 VO motion prior は micro F1 76.2 (source-video block bootstrap 95% CI: 73.7–78.4)、MCC 0.698、推定費用 \$13.48/1,000 clips であった。Cosmos3-Nano / adaptive 24-reasoned に対する Cosmos3-Nano / uniform 24-reasoned の paired F1 差は +0.5 points (95% CI: -0.2–+1.2) であった。公開 ROAD 動画から推定した VO を用いる固定 motion prior により、Super の F1 を 74.5 から 76.2 へ改善した。Development では、難しい 5 タグだけを詳細化する Hybrid Core Reasoning が、短い Prompt の F1 72.2 を 75.6 へ改善した。Development 難例診断では、GT event 近傍を 48 frames へ高密度化して 5/14 FN を回復した。タグ別の未校正 YES score は Recall–Precision 交換を制御できた。さらに、予測ラベルによる分布推定誤差と希少シーンの人手確認効率を評価し、自動ラベリングの利用可能範囲と限界を示す。

キーワード: 自動運転、視覚言語モデル、動画理解、シーンラベリング、active learning、データキュレーション

1. はじめに

自動運転システムの開発では、長時間の走行動画から学習・検証に有用な区間を抽出し、データ集合の偏りや long-tail scenario を把握する必要がある。物体検出 box のような局所注釈だけでなく、「自転車が車線変更した」「歩行者が横断を待っている」「先行車が制動した」といった時間的 scene label は、データ検索、失敗分析、評価 set 設計および active learning の acquisition に利用できる。しかし、全動画を人手で網羅的に確認する費用は大きく、正例探索だけを目的とした弱い Ground Truth では false positive を測れないため、モデルが yes を過剰出力しても高く評価され得る。

本研究の目的は、(i) 完全な正負 GT 上で Vision-Language Model (VLM) の時系列 multi-label 分類能力を測ること、(ii) 入力 frame と request 構成が品質・latency・費用へ及ぼす影響を分離すること、(iii) 生成ラベルが分布推定と希少 scene 抽出に与える実用的価値を測ることである。主な貢献は次の 7 点である。

1. ROAD の密な注釈から、unknown を明示した再現可能な 13 タグ・8 秒 clip benchmark を構築した。
2. 24-frame budget 下で Uniform、Adaptive、Hybrid および診断用 sampling を比較し、timestamp manifest と reasoned prompt を組み合わせた evidence 生成法を設計した。
3. タグの意味、肯定証拠、時系列検査、除外条件を分離し、難しい 5 タグだけを詳細化する Hybrid Core Reasoning を development で固定した。
4. 低 Recall タグについて、GT 時刻を用いる 24/48-frame Oracle、空間 crop、匿名 track およびタグ別 YES/NO score を段階的に比較し、見逃し原因を分解した。
5. continuous batching、Chunked Prefill、MM/prefix cache、request 順序を統制し、Prefill/Decode、tail latency および GPU 費用への作用を分離した。

6. Nano–Super cascade、分布誤差、希少 scene retrieval、source-video block bootstrap を含む、品質と運用費用を同時評価する再現可能な実験系を提示した。

7. 公開 RTK 派生軌跡と video-derived VO を quality gate 付きで統合し、evaluation へ再調整せず適用できる自転車運動 fusion を構築した。

2. 関連研究

2.1 道路事象 dataset

ROAD は Oxford RobotCar 動画に対し、agent、action、location、ego action および複合 road event を frame/track 単位で注釈した dataset であり、online event detection や anticipation を目的としている [1, 2]。本稿は bounding-box detection を再学習するのではなく、公開注釈を clip-level の multi-label GT へ決定論的に変換し、汎用 VLM による off-line labeling を評価する。

2.2 VLM と動画推論

Cosmos 3 は language、image、video、audio、action を統一 architecture で扱う omnimodal world model family である [3]。本研究は同 family の Nano/Super を対象とし、モデル規模だけでなく入力時系列と serving 構成を比較する。大量 video token の処理では prefill が支配的になり得るため、PagedAttention、continuous batching および prefix reuse を実装する vLLM[4] 上で計測した。

2.3 Active learning とデータキュレーション

自動運転における active learning は、限られた注釈予算で情報量・多様性の高い frame を選択する問題として研究されている [5, 6]。本稿では downstream model の再学習効果を直接主張せず、VLM 予測で人手確認対象を優先したときの Precision@K、Recall@K、random sampling 比 enrichment を proxy として測る。

3. 問題設定と評価方針

本研究は、8 秒の走行 clip $v \in \mathcal{V}$ に対し、複数の道路事象タグ $t \in \mathcal{T}$ を同時付与する multi-label classification として定式化する。ROAD の注釈から clip-tag pair ごとに positive、negative、unknown を構成し、unknown は品質指標の母数から除外した。一方、モデルが構文解析可能な回答を返さない場合や、要求したタグを欠落させた場合は abstention $\perp$ として保存し、正答へ丸めず strict 指標へ反映した。この扱いにより、出力失敗を陰性予測として隠蔽せず、推論系全体の信頼性を分類品質と同時に評価する。

品質比較には Precision、Recall、F1、Accuracy、Balanced Accuracy (BA) および Matthews Correlation Coefficient (MCC) を用いるが、モデル選定の中心は F1 と MCC とした。Accuracy は負例の多い multi-label 問題で過大に見え得るため補助指標とし、出力 pair coverage が 99% 未満の条件は候補から除外した。また、近接する clip を独立標本と仮定すると信頼区間を過小評価するため、個々の clip ではなく source video を再標本化単位とする 10,000 回の block bootstrap を採用した。

自動ラベルを dataset 解析へ用いる妥当性は、タグ別 prevalence の Mean Absolute Error (MAE) と Jensen-Shannon divergence (JSD) で測定した。前者は各タグの出現率を何ポイント誤るか、後者はタグ構成全体が GT 分布からどの程度乖離するかを表す。希少 scene 抽出については、予測 positive を先に人手確認した場合の Precision@K、Recall@K および random sampling 比 enrichment を報告し、分類精度とは別にデータキュレーション上の効用を評価した。

3.1 研究課題と検証仮説

本稿では、品質だけを最大化する単一の model 比較ではなく、入力生成から GPU serving までを含む系全体を対象として、次の研究課題を設定した。

- RQ1:** 限られた frame budget の下で、均等 sampling、motion 集中 sampling、timestamp 表現および判定手続のうち、どの要因が時系列タグの品質を支配するか。当初は短時間 event へ局所高 FPS を割り当てる Adaptive/Hybrid 方式が有利と仮定した。
- RQ2:** タグ定義へ肯定証拠、時系列検査、除外条件を追加する Reasoning 強化は、全タグ一律よりも難しいタグへ限定した方が品質と Prompt 長を両立できるか。
- RQ3:** Nano から Super への model 規模拡大は、見逃し削減と誤検出削減のどちらへ主に作用し、その改善は追加 EC2 費用を正当化するか。
- RQ4:** continuous batching、Chunked Prefill、MM/prefix cache および request 分割は、throughput、tail latency、Prefill/Decode、費用へそれぞれどのように作用するか。
- RQ5:** 映像だけでは曖昧な自転車走行・停止・旋回を、公開軌跡または video-derived Visual Odometry (VO) で補助すると品質を改善できるか。また、context を再び VLM へ入力する生成的 fusion と、タグ単位の決定論的 fusion のどちらが安定するか。
- RQ6:** event 時刻を既に含む False Negative は、局所 48-frame 化、空間 crop、track 情報、またはタグ別の未校正 YES score のどの段階で回復し、どの誤りが残るか。
- RQ7:** 生成ラベルは個別 clip の分類に留まらず、dataset 分布推定および希少 scene の人手確認順序付けへ利用できるか。

これらを同時に変更すると因果を解釈できないため、RQ1 では model と serving、RQ2 では media と model、RQ4 では media と prompt、RQ5 では映像 baseline を固定した。各候補は Smoke、development、evaluation の順に段階的に絞り込み、evaluation は方式固定後の性能推定にのみ用いた。

4. 公開 GT の構築

ROAD train/validation 18 動画の 101,780 annotated frames (全 101,907 frames の 99.9%) を使用した。8 秒 window、8 秒 stride、12 FPS 原時刻で 1,044 clips を生成し、ROAD 公式 fold 3 に従って development 169 clips (3 動画) と evaluation 875 clips (15 動画) へ分離した。各タグは 6 annotated frames 以上、存在系は 3 frames 以上を positive とし、全 frame が注釈済みで対象 event がない clip を negative、境界欠損を unknown とした。evaluation の unknown は 61 pairs である。使用タグは自転車走行、自転車停止、自転車左折、自転車右折、自転車車線変更、車両制動、停止車両、歩行者横断待ち、歩行者横断、自転車存在、二輪車存在、対象信号赤、対象信号青である。

5. 提案手法

5.1 全体構成

提案系は、(1) 元動画から 24-frame の基準 evidence を生成し、(2) 各 frame の元動画時刻を manifest として保持し、(3) 難しいタグだけ詳細化した Hybrid Core Reasoning で一次判定し、(4) 必要な自転車運動タグだけを公開 VO prior で補正し、(5) 軽量 detector/tracker 等の外部証拠と一次 negative が不一致な場合だけ候補化し、(6) event 近傍 48 frames とタグ別 YES/NO score で Recall を補い、(7) 用途に応じて Nano と Super を routing する、という階層構成である。

clip v から選択した frame 集合を $M(v)$ 、その実時刻列を $\tau(v)$ 、タグ定義と判定手続を D 、VLM を f_θ とすると、映像予測は

$$\hat{y}(v) = f_\theta(M(v), \tau(v), D)$$

で表される。さらに VO 特徴 $\mathbf{z}(v)$ と development で固定したタグ別規則 $g_t(\cdot; \phi_t)$ を用い、対象タグ t だけを

$$\tilde{y}_t(v) = g_t(\hat{y}_t(v), \mathbf{z}(v); \phi_t)$$

へ置換する。規則を持たないタグは $\tilde{y}_t = \hat{y}_t$ とし、物体・歩行者・信号の予測を自転車運動 context で不用意に変化させない。推論時に GT は使用せず、 ϕ_t は development で一度だけ固定する。

本設計の要点は、VLM へ多量の context を与えて全タグを常時再生成させるのではなく、映像が得意な外観・意味判定と、VO が得意な自転車状態判定を責務分離する点にある。また、48-frame pass は全 clip へ適用せず、一次判定と構造化証拠が矛盾するタグだけへ限定する。GT event 時刻を使った結果はこの条件付き pass の上限診断であり、本番の候補時刻は detector/tracker、lane、VO から推定しなければならない。また、Sampling、Prompt、Model、Serving、Fusion を独立した操作因子として扱い、品質差がどの処理に由来するかを追跡可能にした。

5.2 Evidence media の構成

本稿でいう evidence media とは、元動画から選択した静止 frame を時系列順に連結した、VLM 入力用の短い動画である。元動画をそのまま入力する方式と比べ、frame budget を明示的に管理でき、sampling、prompt、serving の各要因を独立に比較できる。8 秒 clip 当たりの基準 budget を 24 frames とし、次の三方式を主に検討した。

Uniform sampling

clip 全域を一定間隔で走査する。最終候補では 3 FPS 相当の 24 timestamps を選択した。detector や motion score に依存しないため、意味的には重要だが画素変化の小さい停止、信号状態、遠方物体を一樣に観測できる。また、処理内容が単純で、動画ごとの前処理時間と選択 frame 数を予測しやすい。

Adaptive sampling

元動画を 4 FPS で軽量解析し、frame 差分と optical flow から motion peak を求めた。近接 peak は 2 秒の non-maximum suppression で統合し、最大 2 箇所を採用する。全域を 1 FPS で保持した上で、peak 前後 2 秒を 2 FPS、中心前後 1 秒を 4 FPS へ高密度化し、24-frame 上限を超える場合は優先度の低い frame と置換した。したがって、高 FPS frame を無制限に追加する方式ではない。

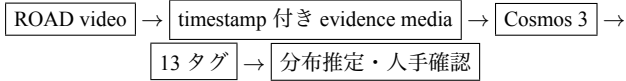
Hybrid sampling

全域を 2 FPS で保持しつつ、8 FPS の motion 解析で選んだ 1 peak の前後 1 秒を補強し、中心前後 0.5 秒だけを 8 FPS 相当とする。Uniform の広域 coverage と Adaptive の局所密度を同一 24-frame budget で両立させる設計である。

これらに加え、局所 burst を 32/48 frames へ増やす条件、GT event の開始・中央・終了を優先する diagnostic oracle、道路上方・左右端を拡大する multi-scale mosaic を development 限定で評価した。oracle は sampling の理論上限を診断するための条件であり、方式選定や evaluation には使用していない。multi-scale も一部小物体を回復したが false positive を増加させたため、Full Run 候補から除外した。

5.3 実時間を保持する timestamp 表現

evidence media は 4 FPS で再生されるため、動画内の見かけの frame 間隔は元動画の実時間間隔と一致しない。特に Adaptive sampling では、隣接 frame が 0.125 秒差の場合と数秒差の場合が混在する。そこで、選択した全 frame の元動画時刻を text manifest として prompt へ付与した。これにより、モデルは単なる画像順序だけでなく、停止の持続時間、接近・離反の速度、右左折前後の時間関係を解釈できる。timestamp 有無のみを比較する条件では、media bytes を hard link で共有し、入力画像差が結果へ混入しないようにした。



5.4 Prompt と request 構成

Timestamp-only prompt

全 13 タグの定義と timestamp manifest を提示し、固定順の binary array を返させる。構造化出力として単純である一方、各タグの時間的根拠を順に照合する手続を明示しないため、後述の実験では negative 側へ過度に保守的になる傾向を示した。

Reasoned prompt

全 frame を時系列順に確認し、タグごとの肯定条件と除外条件を照合してから、最終的な positive index のみを出力する手続を指示した。自由記述の説明文は要求せず、FINAL_POSITIVE_INDICES に相当する短い配列へ制約する。これにより、判定前の確認手続を prompt 上で規定しつつ、decode token 数と parse failure を抑える。最大出力は 64 tokens であり、長い自然言語説明を生成する方式ではない。

Hybrid Core Reasoning

短い baseline 定義はタグの意味を一文で与えるだけであった。これに対し詳細定義では、各タグ t について、(i) 意味、(ii) 追跡すべき対象、(iii) positive を支持する視覚証拠、(iv) 複数 timestamp 間で確認すべき変化、(v) 類似事象を除外する反証、の五要素を $D_t = (m_t, o_t, e_t, \Delta_t, r_t)$ として明示した。モデルには自由記述の思考過程を出力させず、全 frame を時系列順に検査した後の positive index だけを返させる。従って、本稿の Reasoning 強化は長い回答を生成する chain-of-thought ではなく、判定前に実施すべき証拠照合手続を入力契約として構造化する方法である。

全 13 タグを詳細化すると Prompt 長と KV-cache 消費が増え、厳しい除外条件が視覚的に単純なタグの Recall を下げる可能性がある。そこで、Development 上で全タグ詳細化と 3 種の部分詳細化を同一 media・同一 Super で比較した。数値上の最高候補と簡潔な候補の paired 95% CI が 0 を跨ぐ場合は短い方を選ぶ parsimony 規則を事前に採用し、最終的に road-adaptive-24-hybrid-core-v1 を固定した。詳細化対象は自転車左折、自転車車線変更、停止車両、歩行者横断待ち、二輪車存在の 5 タグであり、残る 8 タグは短い定義を維持する。criteria 語数は baseline の 213 語から 603 語へ増えるが、全タグ詳細化より短い。選定には Evaluation を使用していない。

Grouped request

13 タグを ego action、road-user action、object/signal の 3 群へ分割する。同一 media bytes、同一 timestamp manifest、同一 system prefix を維持し、群固有の判定基準だけを末尾へ加える。タグ間干渉の低減が期待できる一方、1 clip 当たり 3 request となるため、品質改善が追加 latency を正当化できるかを実測した。同一 clip の 3 request は連続投入し、multimodal cache と prefix cache が効く順序を意図的に構成した。

5.5 候補駆動 48-frame Recall refinement

一次 pass は 13 タグを一括して高 Precision に判定する一方、negative 出力には、証拠不足、タグ間競合、実効判定閾値の高さが混在する。そこで本稿は、全 clip を一律に高 FPS 化せず、軽量 detector/tracker、lane、VO などの外部証拠がタグ t を支持し、一次予測が negative である場合だけ routing 変数 $q_t(v) = 1$ とする条件付き second pass を提案する。

$$q_t(v) = \mathbb{I}[\hat{y}_t(v) = 0 \wedge c_t(v) \geq \gamma_t],$$

ここで $c_t(v)$ はタグ固有 candidate score、 γ_t は Development で固定する閾値である。 $q_t(v) = 1$ のとき、candidate 時刻の前後を 8 FPS で密にし、全域 context を残した 48 frames $M_{48,t}(v)$ を生成する。48 枚は追加し続けるのではなく、低優先の全域 frame と置換して budget を固定する。

second pass は対象タグだけを YES/NO で問い合わせ、先頭 token の log probability から

$$s_t(v) = \frac{\exp \ell_{\text{YES}}}{\exp \ell_{\text{YES}} + \exp \ell_{\text{NO}}}$$

を得る。 s_t は校正済み確率ではなく、YES/NO 間の相対的な未校正 score である。最終判定は独立 calibration で固定するタグ別閾値 η_t と、lane 境界横断、相対速度、person-road 交差、自転車 lane に対応する信号、brake-lamp 変化等の構造化 veto/promotion で決める。13 タグすべてを個別 call する設計ではなく、candidate になったタグだけを再確認する。

この本番形の候補生成器はまだ Full Run していないため、本稿では自転車車線変更、歩行者横断待ち、歩行者横断、停止車両、対象信号青、車両制動、自転車存在の 7 タグを対象とし、GT event 時刻、GT box、匿名 track を順に用いる Oracle 診断で各情報源の上限を分解した。GT action/class 名は Prompt へ渡していない。Oracle 48 の回復は candidate-guided 48-frame 設計の可能性を示すが、本番性能の証明ではない。

5.6 Serving 最適化

VLM 推論を、動画・prompt を内部表現へ変換する Prefill と、最終回答 token を生成する Decode へ分けて計測した。動画入力では Prefill 負荷が大きくなりやすい一方、本手法は短い index 配列のみを continuous batching は、異なる request の Prefill と Decode を GPU scheduler が逐次組み合わせ、GPU の遊休時間を減らす機構である。本稿では同時投入上限を concurrency 1/2/4/8 と変化させ、aggregate throughput と request 単位の tail latency を同時に測った。concurrency を上げれば GPU 利用率は向上するが、KV cache の競合、待ち行列、再計算によって P95 latency や preemption が悪化し得る。

Chunked Prefill は長い Prefill を一定 token 数の chunk へ分割し、他 request の Decode を割り込ませる。2,048 および 8,192

token budget を比較し、短い応答を持つ 24-frame workload でも効果があるかを検証した。また、同一 video embedding を再利用する multimodal (MM) cache と、共通 prompt token を再利用する prefix cache を区別して記録した。cache 効果を測る run では同一 clip を連続投入する video-grouped-hot、純粋な serving 比較では順序を乱す shuffled-cold を用いた。

5.7 公開自転車運動 context とタグ限定 fusion

公式 Oxford RobotCar の生 INS/GNSS は学術機関認証を要するため使用せず、認証不要の OPR 公開派生物 [7] と ROAD 動画だけから再計算可能な VO を用いた。OPR 画像と ROAD frame は perceptual hash で対応付け、複数 anchor 間の frame 時刻を区分線形補間した。frame coverage 70% 以上かつ leave-one-anchor-out 時刻誤差 P95 2 秒以下を同期 quality gate とし、条件を満たさない走行は外挿せず VO へ fallback した。公開 OPR 派生軌跡は quality gate 後に 341 clips・6 source videos をカバーした。video-derived VO は 875 clips・15 source videos へ同一条件で適用した。

VO では元動画を 5 frames 間隔、幅 480 px へ縮小して走査した。空や道路中央の移動物体に偏らないよう背景寄りの領域から最大 800 個の Shi-Tomasi 特徴点を抽出し、Lucas-Kanade 法で前後追跡した。forward-backward 誤差 1.5 px 以下かつ 20 tracks 以上を有効 pair とし、median flow、0.8 px 未満の low-motion pair 率、Essential Matrix の RANSAC inlier および累積 visual yaw を clip 単位へ要約した。yaw は inlier 率 0.25 以上の pair だけを集計し、全 pair の 50% 以上が有効な clip だけを fusion 対象とした。

生成的 fusion では、これらの数値を自然言語 context として Super へ再入力し、自転車 action を再判定させた。一方、提案する決定論的 fusion では、映像予測を保持したまま、development 上の grid search で F1、MCC、BA が改善し、かつ改善 pair 数が悪化 pair 数以上となる規則だけを採用した。条件を満たさないタグは identity へ戻した。Evaluation では閾値を変更せず、追加 VLM request を発生させない。採用規則は次の通りであり、3 タグだけを変更し、残る 10 タグは映像出力を保持した。

表 1: Development で固定した VO motion prior 規則

対象タグ	映像予測を変更する条件
自転車走行	no→yes: median flow が 0.50 px 以上かつ low-motion 率が 0.75 以下。yes→no: flow が 0.05 px 以下かつ low-motion 率が 0.50 以上
自転車停止	no→yes: flow が 0.05 px 以下、または low-motion 率が 0.10 以上。yes→no: flow が 1.00 px 以上かつ low-motion 率が 0.05 以下
自転車左折	yes を維持するのは累積 visual yaw が正方向へ 3.0° 以上の場合だけ

このタグ限定設計は、motion 情報が歩行者、物体、信号色などへ直接の根拠を持たないという帰納 bias を明示する。すなわち、VO を VLM の代替分類器として用いるのではなく、映像だけでは曖昧な自転車状態に対する支持または veto として用いる。

5.8 Nano-Super cascade

全件を高価な Super へ投入せず、まず Nano で一括判定し、Nano の予測だけから再確認対象を選ぶ二段構成を評価した。routing 条件は、positive 数が 3 以上、歩行者系 positive を含む、複雑時系列タグ positive を含む、の三種である。routing 判断に GT は使用せず、選択された clip だけ Super の出力へ置換した。この設計により、Nano のみと Super 全件の間に複数の実測運用点を構成する。

6. 実験設定

development では 15 clips の class-balanced Smoke で明らかに劣る条件を除外し、その後全 169 clips で sampling/prompt を選定した。evaluation 875 clips は条件固定後に一度だけ Nano/Super へ適用した。temperature 0、seed 20260808 とし、モデル、prompt、

media、container digest、instance、GPU telemetry および全 SHA-256 を lock artifact へ保存した。Smoke は方式探索、development は方式選定、evaluation は最終性能推定という役割を持ち、evaluation 結果を見て sampling や prompt を再調整しない三段階設計とした。さらに、sampling 比較では prompt と model を固定し、serving 比較では media と prompt を固定することで、複数要因を同時に変更した比較を避けた。

Recall 原因診断は、development から低 Recall 7 タグについて、時間的に covered であった False Negative 2 件、True Positive 1 件、negative control 1 件をタグごとに選び、重複を共有した 24 clips で実施した。この集合は難例を意図的に濃縮しているため、診断上の P/R/F1 を ROAD 母集団性能として扱わず、FN 回復数、TP 維持数、negative-control FP 数を主に報告する。GT event 時刻および ROAD box を用いる条件は原因切り分け専用であり、Evaluation の最終方式へ混入させていない。

表 2: 実験結果の証拠水準と許容する主張

水準	使用データ・GT 利用	本稿で許容する主張
Population evaluation	未使用 Evaluation 875 clips、推論入力へ GT 不使用	固定方式の母集団品質、分布誤差、費用
Development selection	169 clips、方式・閾値の選定	候補間の選定根拠。母集団性能とはしない
Oracle diagnostic	難例 24 clips、時刻・box 選択へ GT 使用	原因分解と到達可能性。実運用性能とはしない
Production proposal	detector/tracker 等で候補を近似	実装仮説。固定 Evaluation での検証を今後要する

Nano は g6e.2xlarge (1 GPU)、Super は g6.24xlarge (4 GPU) で実行した。後者は GPU 間が PCIe-only で vLLM custom all-reduce を利用できず、NCCL fallback を含む実測である。EC2 定常推論費用は、artifact に記録した on-demand 単価 p と item 当たり wall 時間 t から

$$C_{1000} = p \frac{t}{3600} \times 1000$$

で算出した。観測単価は us-west-2 における g6e.2xlarge の \$2.24208/h と g6.24xlarge の \$6.6752/h である。EKS control plane、EBS、NAT、data transfer、model download、compile、idle 時間は含めない。したがって本稿の費用は、十分な request が継続して供給される定常状態の EC2 下限に相当する。低頻度運用では model 起動と idle 時間を償却できず、実際の 1 clip 当たり費用は増加する。

6.1 段階的実験設計と採用基準

実験は、少数で方式の成立性を確かめる Smoke、未知条件へ進める方式を固定する development、最終性能を一度だけ推定する evaluation に分けた。各段階の役割を混同しないため、次の採用規則を設けた。

- Smoke では request failure、parse failure、preemption および明らかな品質劣化を確認し、不安定な条件を全 development へ拡張しない。
- Development では coverage 99% 以上を必須とし、F1、MCC、Balanced Accuracy を主に、費用と latency を副に用いて Pareto 候補を選ぶ。複雑な方式は単純 baseline を上回る場合だけ evaluation 候補とする。
- Evaluation では条件・閾値・prompt を再調整しない。差は source-video 単位 paired bootstrap で評価し、CI が 0 を跨ぐ場合は明確な改善と主張しない。
- 追加 VLM pass は、対象タグの改善が追加費用と誤変更を上回る場合だけ採用する。全体 F1 が僅かに上がっても、無関係タグの揺らぎが支配する条件は棄却する。

表 3: 研究課題ごとの操作因子、固定条件および判断目的

課題	変更した因子	固定した条件・判断目的
RQ1	Sampling, timestamp, prompt, request 分割	同一 clip・model・frame budget. 品質差の原因を入力設計へ限定
RQ2	短い定義、全タグ詳細化、Hybrid Core	同一 169 clips・media・Super. 詳細化範囲と Prompt 長を比較
RQ3	Nano / Super	同一 evaluation clips・media・prompt. model 規模の効果を測定
RQ4	concurrency, Prefill chunk, cache 順序	同一 15 clips・media・prompt. 速度、tail、費用を分離
RQ5	OPR/VO context, 決定論的 prior, Map pass	映像 baseline 固定. 改善・悪化 pair と追加 pass 費用で採否
RQ6	Oracle 24/48, ROI, track, tag score	Development 難例 24 clips. 時間・空間・競合を段階分解
RQ7	予測ラベルによる集計・ranking	同一 GT. 分布誤差と人手確認濃縮率を分類品質と分離

7. 実験結果

本節では、各実験を「検証意図、観測結果、解釈、次段階への採否」の順に記述する。Smoke 値は方式探索または serving 境界の確認に限って用い、最終品質の主張は Full Run に限定する。

7.1 Development ablation

表4は全 development split の条件選定結果であり、evaluation 性能ではない。

表 4: Development split における入力・prompt ablation

条件	P	R	F1	BA	MCC
uniform 24-reasoned	74.1	68.4	71.1	80.2	0.621
hybrid-24-reasoned	72.1	68.6	70.3	79.9	0.608
adaptive 24-reasoned	73.3	67.3	70.2	79.6	0.609
adaptive 24-reasoned-v2	73.6	66.2	69.7	79.1	0.605
adaptive 24-grouped	50.6	50.0	50.3	66.9	0.339
uniform 4fps+timestamp	85.9	32.4	47.0	65.3	0.453
adaptive 24+timestamp	67.9	34.6	45.8	64.6	0.378
uniform 2fps+timestamp	64.8	30.5	41.5	62.5	0.336

表 5: Development における Reasoning Prompt の選定

Prompt	criteria	語数	詳細タグ	P	R	F1	MCC	tokens	P95[s]
短い Reasoned baseline		213	0	86.2	62.1	72.2	0.663	7785	17.5
全タグ Contrastive		1273	13	85.6	65.8	74.4	0.683	9234	43.2
Hybrid Core (採用)		603	5	85.6	67.6	75.6	0.695	8348	31.8
Hybrid Temporal		778	7	85.8	67.8	75.8	0.697	8551	39.2
Hybrid F1-selected		850	8	84.9	66.4	74.5	0.682	8646	44.8

短い baseline に対し、全タグ Contrastive は Recall を改善したが、Prompt を一律に長文化した。Hybrid Core は F1 を +3.34 points 改善し、source-video 単位 paired bootstrap 95% CI は +1.38~+4.46 points で 0 を跨がなかった。数値上は Hybrid Temporal が 0.21 points 高かったが、Core との差の 95% CI は -0.45~+0.63 points であり、統計的に区別できなかった。このため、criteria が 22.5% 短く、詳細化対象も少ない Hybrid Core

表4の各行は、同一 development clips に対して入力 frame の選び方、timestamp 表現、判定手続および request 分割だけを変更した条件である。uniform 24-reasoned は Precision 74.1、Recall 68.4、F1 71.1、MCC 0.621 で最良となった。これに対し、motion peak を用いる hybrid および adaptive は Recall を同程度に維持したものの、Precision または MCC で上回らなかった。画素変化の大きさは必ずしも意味的 event の重要度と一致せず、信号状態、停止、遠方の歩行者といった低 motion 事象を均等 sampling が安定して保持したためと考えられる。

timestamp のみの条件は Precision が高い一方、Recall が 30~35% 程度へ低下した。これはモデルが確実な positive だけを返す保守的な判定へ偏ったことを示す。同じ frame budget でも reasoned 手続を加えると F1 が約 70% へ上昇しており、本問題では frame 数の増加より、全時刻と除外条件を照合させる prompt 構成が支配的であった。grouped は cache 再利用を可能にするものの、タグ群ごとに文脈が分断され、この条件では品質改善を示さなかった。以上から、Full Run には単一 request の reasoned 条件を採用し、uniform と adaptive を最終候補とした。

7.2 タグ選択型 Reasoning Prompt

表5は、同一 Development 169 clips、同一 24-frame media、同一 Cosmos 3 Super、temperature 0 で、詳細定義を適用するタグ集合だけを変更した結果である。候補 3 条件は同一 run 内でランダムに混在させ、特定 Prompt だけが warm state を先取りする偏りを抑えた。P95 はこの混在 run における参考値であり、独立 cold run の費用比較ではない。

を採用した。この選択は「最大値を出した Prompt」を後追いで採るのではなく、同等群から複雑さの小さい方式を選ぶことで Development への過適合を抑える判断である。なお、この 75.6% は Development 値であり、Evaluation 性能ではない。

7.3 Evaluation Full Run

表6は固定した同一 875 clips に対する Full Run のみを示す。

表 6: Evaluation split における完全 GT 品質 (Full Run のみ)

Model/条件	clips	coverage	Precision	Recall	F1	Accuracy	BA	MCC
Cosmos3-Nano / adaptive 24-reasoned	875	100.0	71.3	66.7	68.9	85.6	79.1	0.596
Cosmos3-Nano / uniform 24-reasoned	875	100.0	73.4	65.9	69.4	86.1	79.2	0.606
Cosmos3-Super / adaptive 24-reasoned	875	100.0	81.9	68.3	74.5	88.8	81.8	0.678

表6は、development で方式を固定した後に初めて実行した 875 clips の結果である。全条件の coverage が 100% であるため、差は出力欠落ではなく判定内容に起因する。Nano の uniform 化は adaptive 比で Precision を 71.3 から 73.4 へ改善した一方、Recall を 66.7 から 65.9 へ低下させ、F1 差は +0.5 points に留まった。paired bootstrap の 95% CI は -0.2~+1.2 points で 0 を含むため、development で観測した優位が未知動画へ明確に一般化したとは結論しない。ただし、単純な uniform 方式が複雑な motion 解析と同等の品質を示したこと自体は、前処理実装と運用保守を簡素化できる点で重要である。

Super は Nano adaptive 比で Precision を 10.6 points、Recall を 1.6 points 改善し、F1 74.5、MCC 0.678 に達した。改善の中心は false positive の抑制であり、より大きな model が時系列 event を一律に多く発見したというより、肯定条件と除外条件を厳密に区別した結果と解釈できる。一方、定常 EC2 費用は Nano の約 20 倍であり、品質差だけから全件 Super を選ぶことはできない。

表 7: タグ別 F1。“-”は陽性予測または有効分母がなく F1 を定義できない場合を示す

タグ	GT 陽性	Cosmos3-Nano / adaptive 24-reasoned	Cosmos3-Nano / uniform 24-reasoned	Cosmos3-Super / adaptive 24-reasoned
車両制動	152	57.8	59.9	56.1
停止車両	272	52.2	53.5	44.9
自転車存在	432	72.1	69.2	83.1
自転車線変更	20	15.4	12.5	15.0
自転車走行	701	94.5	94.7	93.4
自転車停止	264	88.4	90.0	90.7
自転車左折	61	28.2	27.8	59.8
自転車右折	59	62.0	56.5	55.8
二輪車存在	34	74.2	78.7	80.0
歩行者横断	205	48.0	46.6	48.2
歩行者横断待ち	123	25.8	26.1	28.3
対象信号青	163	60.7	64.2	73.6
対象信号赤	226	77.3	77.6	83.3

表7は、micro 平均では隠れるタグごとの難易度差を示す。自転車走行・自転車停止は陽性例が多く、継続的な視覚変化も明瞭であるため、全 model で F1 88 以上となった。対象信号赤、自転車存在、二輪車存在では Super の誤認抑制が寄与した。一方、自転車線変更は全条件で F1 15 前後、歩行者横断待ちは 30 未満であり、静止画的な物体存在だけでなく、lane 境界との関係、対象 track の継続、将来意図を判定する必要がある。

Super は自転車左折を 28.2 から 59.8 へ大きく改善したが、停止車両や自転車右折では Nano を下回った。したがって、model 規模の増加は全タグへ一様に作用しない。特に陽性数 20 の車線変更や 34 の二輪車存在は推定分散が大きく、数 points の順位を一般化すべきではない。運用上は、全体 F1 だけで model を選ぶのではなく、収集目的となるタグの陽性数、タグ別 F1 および誤り費用を併せて評価する必要がある。

7.4 48-frame・ROI・未校正 YES score による Recall 上限診断

本診断は Development から意図的に抽出した 24 clips、28 clip-tag pairs であり、ROAD 母集団の性能推定ではない。各低

Recall タグについて、時間的に covered な FN 2 件、TP 1 件、negative control 1 件を選び、hard-label 条件では 14 FN の回復、7 TP の維持、7 controls に対する FP を数えた。

表 8: 低 Recall タグに対する入力証拠の上限診断

条件	FN 回復	TP 維持	control FP	frames	E2E[s]	USD/1k proxy
Baseline 24	0/14	7/7	5/7	22.9	17.46	16.19
Oracle 時刻 24	2/14	7/7	4/7	24.0	18.27	16.94
Oracle 時刻 48	5/14	7/7	4/7	48.0	21.40	19.84
48 + multiscale	3/14	6/7	2/7	48.0	20.63	19.12
48 + GT-box ROI	4/14	5/7	3/7	48.0	19.38	17.96
ROI + VO	3/14	5/7	1/7	48.0	20.27	18.79
ROI + 匿名 track + VO	5/14	5/7	3/7	48.0	20.75	19.24

同じ 24-frame budget で GT event 周辺へ再配置すると 2/14 件、48 frames へ増やすと 5/14 件を回復し、TP 7/7 を維持した。従って、event frame を 1 枚以上含むことと、行動を判定できる局所時間密度を持つことは同義ではない。一方、GT 時刻を知る 48 frames でも 9 件は hard label のまま残り、時間密度だけで見逃しを解消する仮説は棄却された。

GT-box ROI や mosaic は一部を回復したが TP も失った。

crop は元画素を増やさず、mosaic 化は全体 context を変形するためである。匿名 track + VO は停止車両に有効だったが、自然言語 context を全タグへ混ぜると無関係タグが揺れた。従って、本番では full-frame を保持し、candidate track の高解像度 still/sequence を追加し、構造化証拠は対象タグだけへ融合すべきである。

表 9: タグ別の未校正 YES/NO score による探索的閾値比較

Media	threshold	FN 回復	TP 維持	control FP	診断 P	診断 R
Baseline 24	0.05	10/14	7/7	6/7	73.9	81.0
Baseline 24	0.20	8/14	7/7	4/7	78.9	71.4
Baseline 24	0.40	6/14	7/7	4/7	76.5	61.9
Oracle 48	0.05	11/14	7/7	5/7	78.3	85.7
Oracle 48	0.20	8/14	7/7	3/7	83.3	71.4
Oracle 48	0.40	7/14	7/7	2/7	87.5	66.7

Oracle 48 の閾値 0.05 では 11/14 FN を回復したが、control FP も 5/7 となった。閾値 0.20 では 8/14 回復、3/7 FP となり、Recall と Precision の交換を明示的に制御できた。Baseline 24 でもタグ別判定だけで多くの FN が回復したことから、見逃しには視覚証拠不足だけでなく、13 タグ同時判定における tag competition、positive index 抑制、実効閾値が関与する。ただし s_t は log probability を YES/NO 間で正規化した未校正 score である。閾値は同じ小規模診断集合で比較した探索値であり、独立 calibration なしに本番へ固定してはならない。費用列は mean request latency を concurrency で割った queue-adjusted

proxy で、1,000 clips ではなく 1,000 routed tag checks 相当の参考値である。

表 10: 低 Recall タグの診断結果と本番で必要となる追加証拠

タグ	診断で観測した制約	本番で近似すべき証拠
車線変更	時刻を増やしても lane 移行を同定できない	lane 境界横断、道路方向に対する横軌跡
横断待ち	人物の存在だけでは意図を決められない	person track、緑石距離、身体方向、停止時間
歩行者横断	小物体と ego motion で移動方向が曖昧	person-road ROI 交差、進入・退出時系列
停止車両	匿名 track 追加で 2/2 FN を回復	ego 補償済み相対速度、stationary duration
青信号	crop 後も元画素と自車 lane 対応が不足	高解像度信号 crop、lane-signal association
車両制動	尾灯、反射、減速度を区別できない	rear crop の点灯差分と相対減速度
自転車	遠方で二輪車・人物との識別が不安定	class-aware detector crop と同一 track の複数時刻

7.5 Evidence • prompt 構成と実行時間

表11は ROAD development Smoke における入力・request 構成の計測であり、品質の最終比較には用いない。同一 clip と同一 model 上で uniform sampling、adaptive evidence、reasoned output、3-group request を比較した。grouped 条件では同一 media の follow-up を連続実行し、multimodal/prefix cache を再利用した。この選定 run は profile を clip ごとに連続する video-grouped-hot 順序で実行したため、adaptive 行は先行 profile の MM cache を利用し得る。したがって表11は stage と cache の観測に用い、profile 間の cold latency 比較には用いない。

表 11: ROAD Smoke における evidence • prompt 構成別の実行時間

Model/条件	req/clip	wall/clip[s]	P95[s]	prefill[s]	decode[s]	MM hit	Prefix hit	preempt.	USD/1k
Cosmos3-Nano / uniform 1fps+timestamp (c1)	1.0	2.81	2.13	0.33	1.20	0.0	1.6	0	1.75
Cosmos3-Nano / uniform 2fps+timestamp (c1)	1.0	3.70	2.74	0.66	1.21	0.0	0.9	0	2.31
Cosmos3-Nano / uniform 4fps+timestamp (c1)	1.0	5.56	4.12	1.40	1.18	0.0	0.5	0	3.46
Cosmos3-Nano / uniform 8fps+timestamp (c1)	1.0	5.60	4.14	1.44	1.12	0.0	0.4	0	3.49
Cosmos3-Nano / adaptive 24+timestamp (c1)	1.0	2.03	1.71	0.05	1.09	100.0	95.3	0	1.27
Cosmos3-Nano / adaptive 24-reasoned (c1)	1.0	1.04	0.87	0.09	0.37	100.0	89.5	0	0.65
Cosmos3-Nano / adaptive 24-grouped (c1)	3.0	3.83	1.04	0.18	1.68	100.0	93.1	0	2.39

表11の第2列は1 clip を判定する request 数、第3列は run 全体の経過時間を clip 数で割った実効処理時間である。P95 は request latency の遅い側 5% 点を表す。Prefill と Decode は vLLM metrics から得た stage 時間、MM hit と Prefix hit はそれぞれ動画特徴および prompt prefix の再利用率である。実効処理時間は運用費用に直結する throughput 指標、P95 は個々の利用者が経験し得る待ち時間、stage 時間は最適化対象の所在を示す。

Uniform 条件では1 FPS から8 FPS へ増やすにつれ、wall/clip と費用が概ね増加したが、decode 時間はほぼ一定であった。これは追加 frame が主として Prefill 負荷を増やし、短い回答形式によって Decode 負荷が frame 数から分離されていることを示す。adaptive 24-reasoned は出力を positive index へ限定することで、同じ 24-frame 級でも wall/clip を低く保った。grouped は MM cache 100%、Prefix cache 93.1% を達成したが、3 request の Decode と scheduler overhead が累積し、単一

reasoned request より高価となった。従って、cache hit 率の高さだけを最適化目標にしてはならず、再利用後に残る request 数と Decode 量を含む end-to-end 時間で採否を決める必要がある。

7.6 制御された Serving 最適化実験

表12は、ROAD の同一 15 clips、adaptive 24-frame media、reasoned prompt、temperature 0 を固定した serving sweep である。Nano は各 point で pod を再作成し、server default の concurrency 1/2/4/8 と、concurrency 4 における Chunked Prefill budget 2,048/8,192 tokens を比較した。Super は concurrency 4/8 を比較した。これらは少数 Smoke であるため、latency の一般的な母平均ではなく、本構成における性能境界として解釈する。cost は on-demand 時間単価と run wall time から算出し、storage、control plane、model download、compile、idle startup を除く。

表 12: ROAD 同一 15 clips による serving controlled sweep

Model/条件	req/clip	wall/clip[s]	P95[s]	prefill[s]	decode[s]	MM hit	Prefix hit	preempt.	USD/1k
Cosmos3-Nano / server default (c1)	1.0	3.62	2.58	0.96	0.38	0.0	0.6	0	2.26
Cosmos3-Nano / server default (c2)	1.0	1.95	3.76	1.14	0.74	0.0	0.6	0	1.22
Cosmos3-Nano / server default (c4)	1.0	1.38	5.78	1.40	1.44	0.0	0.6	0	0.86
Cosmos3-Nano / server default (c8)	1.0	1.23	14.50	1.59	3.48	0.0	0.6	0	0.77
Cosmos3-Nano / Chunked Prefill 2,048 (c4)	1.0	1.41	5.77	1.36	1.45	0.0	0.6	0	0.88
Cosmos3-Nano / Chunked Prefill 8,192 (c4)	1.0	1.60	6.02	1.29	1.78	0.0	0.6	0	1.00
Cosmos3-Super / TP4, Chunked Prefill 8,192 (c4)	1.0	7.38	30.47	11.52	9.52	0.0	0.6	0	13.68
Cosmos3-Super / TP4, Chunked Prefill 8,192 (c8)	1.0	6.97	67.36	17.51	16.49	0.0	0.6	4	12.93

表12では、同一 media、同一 prompt、同一 15 clips を固定し、serving 設定だけを変更した。c1 から c8 は同時に処理待ちとする request 数を表し、値が大きいほど GPU へ仕事を供給しやすい一方、各 request の待ち時間と KV-cache 消費が増える。Chunked Prefill の 2,048/8,192 は、一度に scheduler へ渡す prefill token budget であり、model の最大 context 長ではない。preempt. は KV-cache 不足等により進行中 sequence を退避・再計算した回数で、0 であることを安定運用の重要な gate とした。

ROAD の同一 15 clips を cold start 後に処理した Nano では、server default の concurrency 1 から 4 で throughput が 2.62 倍となり、EC2 費用は \$2.26 から \$0.86/1,000 clips へ 61.8% 低下した。一方、P95 latency は 2.58 秒から 5.78 秒へ増加し、c8 では 14.50 秒となった。concurrency 4 における Chunked Prefill 2,048

tokens は 8,192 tokens 比で throughput が 1.14 倍であり、prefill は 1.36 秒/clip 対 1.29 秒/clip であった。ただし server default c4 の費用は \$0.86/1,000 clips で、2,048-token 条件の \$0.88 を下回り、Chunked Prefill の明確な優位は認められなかった。3-group request では同一 media を連続再利用し、MM cache hit 100.0%、Prefix cache hit 93.1% を観測した。Super では c4 の preemption が 0 件であったのに対し、c8 は 4 件、P95 67.36 秒となったため、Full Run には c4 を採用した。これらの結果は、throughput 最大化と tail latency、KV-cache 容量および再計算回避を同時に考慮する必要があることを示す。

7.7 Sampling coverage

GT event 区間と入力 timestamp を照合し、event を 1 枚以上含む率、2 枚以上含む率、0.5 秒以上の時間 span、および event

前後 context を測定した。これは方式選定後の品質評価とは別の原因診断であり、GT 時刻を推論入力を選択には使用していない。

表 13: Development における sampling coverage

条件	frames	any	2 frames	span	context
adaptive 24-reasoned-v2	23.3	100.0	97.4	96.1	100.0
hybrid-24-reasoned	23.2	100.0	98.9	97.1	100.0
uniform 24-reasoned	24.0	99.8	98.9	97.1	89.2

any は GT event 区間内の frame を 1 枚以上含む率、2 frames は時系列変化を比較できる最低 2 枚を含む率、span は選択 frame が event 内で 0.5 秒以上に広がる率、context は event 開始前と終了後の双方を含む率である。Hybrid は 2-frame coverage と span で最良、Adaptive は boundary context で最良となった。Uniform は context が 89.2% へ低下した一方、development F1 では最良であった。これは、event 境界を機械的に多く含めることと、VLM が正しく意味判定することが同値ではないことを示す。motion peak への過度な集中より、clip 全体の均等な観測が有効であった。

表 15: ROAD 15 clips を用いた Nano serving 3 反復 (平均 ± 標本標準偏差)

条件	runs	wall/clip[s]	P95[s]	prefill[s]	decode[s]	USD/1k
Chunked Prefill 2,048 (c4)	3	1.38±0.01	5.73±0.12	1.40±0.01	1.44±0.01	0.861±0.007
Chunked Prefill 8,192 (c4)	3	1.54±0.06	5.91±0.10	1.29±0.01	1.77±0.02	0.956±0.039
server default (c1)	3	3.61±0.20	2.60±0.04	0.98±0.00	0.38±0.01	2.245±0.122
server default (c2)	3	1.85±0.01	3.87±0.03	1.14±0.01	0.74±0.01	1.151±0.008
server default (c4)	3	1.38±0.01	5.75±0.06	1.39±0.00	1.43±0.00	0.862±0.003
server default (c8)	3	1.22±0.04	13.78±1.19	1.54±0.04	3.21±0.13	0.759±0.025

3 反復でも default c4 は wall/clip 1.38 ± 0.01 秒、費用 \$0.862±0.003/1,000 clips と安定した。c8 は 1.22±0.04 秒まで短縮したが、P95 は 13.78±1.19 秒へ増加した。Chunked Prefill

7.8 False negative の原因分解

GT 陽性に対する false negative を、event 区間内 frame が 0 枚の temporal miss、2 枚未満または 0.5 秒未満の sparse coverage、および十分な時間 coverage がある covered miss へ分類した。

表 14: Evaluation Full Run の false negative 原因

Model	FN	miss	sparse	covered	miss+sparse
Cosmos3-Nano / adaptive 24-reasoned	904	0	38	866	4.2
Cosmos3-Nano / uniform 24-reasoned	926	5	34	887	4.2
Cosmos3-Super / adaptive 24-reasoned	861	1	41	819	4.9

sampling miss または sparse coverage で説明できる FN は 4.2%–4.9% に留まった。covered miss は、対象が小さい、遮蔽・夜間、taxonomy 境界、prompt 表現、またはモデル能力を含むため、純粋なモデル誤りとは断定しない。

Nano adaptive では 904 FN 中 866 件、Nano uniform では 926 FN 中 887 件、Super では 861 FN 中 819 件が covered miss であった。すなわち、単純な frame 追加によって直接回復し得る誤りは全体の約 5% 未満である。実画像の監査では、遠方の信号・歩行者、自転車の小さな投影面積、夜間・逆光、および停止と減速の taxonomy 境界が含まれた。従って次の改善対象は、一律な FPS 増加ではなく、候補物体 crop、track summary、道路幾何、タグ別 prompt、または model 規模である。

表 16: Nano 予測だけで routing する Nano-Super cascade

方策	Super 率	P	R	F1	MCC	USD/1k
Nano のみ	0.0	73.4	65.9	69.4	0.606	0.69
positive 3 個以上を Super	39.8	79.9	63.0	70.4	0.632	6.05
歩行者 positive を Super	23.7	78.4	63.8	70.3	0.628	3.88
複雑時系列 positive を Super	69.1	83.1	65.8	73.4	0.670	10.01
Super 全件	100.0	81.9	68.3	74.5	0.678	13.48

routing 判定に GT は用いず、Nano の予測 positive だけを使用した。したがって、全件 Super と Nano のみの間に、実測された品質・費用の中間運用点を構成できる。

歩行者系 positive だけを再判定する方策は全 clip の 23.7% を Super へ送り、F1 を 69.4 から 70.3 へ改善し、費用は \$3.88/1,000 clips となった。複雑時系列 positive を routing する方策は 69.1% を Super へ送り、F1 73.4 を \$10.01 で達成した。これは全件 Super の F1 74.5、\$13.48 に近い品質を 25.7% 低い費用で得る中間点である。一方、Nano の見逃しは routing 条件を発火しないため、cascade は Nano の false negative を完全には救済できない。運用方策は誤検出削減を重視するか、見逃し削減を重視するかに応じて選ぶ必要がある。

7.9 公開 motion context と決定論的 fusion

公式 Oxford RobotCar の生 INS/GNSS は学術機関認証を要するため、本稿では使用しない。代わりに、認証不要の OPR 公

開派生物 [7] に含まれる timestamp 画像と粗い RTK 軌跡を用いた。ROAD frame と公開画像を perceptual hash で対応付け、anchor 間を区分線形補間した。frame coverage 70% 以上かつ leave-one-anchor-out 時刻誤差 P95 2 秒以下を同期 quality gate とし、条件を満たさない走行は外挿せず video-derived Visual Odometry (VO) へ fallback した。公開 OPR 軌跡は 341 clips、6 source videos を quality gate 後にカバーした。video-derived VO は 875 clips、15 source videos をカバーした。

VO は静的背景領域の Lucas-Kanade feature track、forward-backward 整合性、Essential Matrix の RANSAC inlier から、median flow、low-motion 率および累積 visual yaw を clip 単位へ要約する。これらを prompt へ自然言語として加える条件に加え、development だけで閾値を固定し、映像 baseline の自転車走行・停止・左折だけを補正する motion prior を評価した。evaluation では閾値を再調整せず、追加 VLM request も発生しない。development の自転車 action 5 タグ再判定は F1 74.6、改

善/悪化 27/8 pairs であった。無関係タグへの揺らぎを避けるため、全文置換は採用しなかった。さらに、公開 OPR 軌跡を固定 OpenStreetMap snapshot[8] (2026-08-09T07:37:40Z, ODbL) へ map matching し、交差点距離、分岐数、信号設備距離、軌跡方位変化を 4 タグ専用 pass へ入力した。信号色は映像だけで判定した。同一 development subset で F1 76.5 から 76.4 へ低下し、3 pairs 改善に対して 7 pairs 悪化した。追加費用は \$12.90/1,000 target clips であったため、Full Run 候補から除外した。

表 17: Evaluation における公開 VO motion fusion

方式	pass	P	R	F1	MCC	改善/悪化
Super 映像 baseline	1	81.9	68.3	74.5	0.678	0/0
固定 VO motion prior	1	82.8	70.5	76.2	0.698	90/16

固定 motion prior は Super baseline の F1 74.5 から 76.2 へ改善した。改善は自車走行、停止、左折に集中し、映像だけでは曖昧な camera motion を補助情報で拘束した効果と解釈できる。最終方式 Motion prior の F1 は 76.2、MCC 0.698 であった。baseline に対する F1 差の 95% CI は +1.3+2.2 points である。粗い RTK 方位を右左折の答えとして直接使わず、同期品質が低い走行は VO へ fallback したため、公開派生データの欠損を正解情報で補っていない。

7.10 分布推定と希少 scene 抽出

表 18: 生成ラベルによる dataset 分布推定

条件	prevalence	MAE	JSD
Cosmos3-Nano / adaptive 24-reasoned	0.084	0.048	
Cosmos3-Nano / uniform 24-reasoned	0.084	0.048	
Cosmos3-Super / adaptive 24-reasoned	0.066	0.022	

表18の prevalence MAE は、13 タグそれぞれの出現率について、予測と GT の絶対差を平均した値である。JSD はタグ構成全体の形状差を表し、0 に近いほど dataset 分布を忠実に再現する。Super は MAE 0.066、JSD 0.022 で Nano を上回り、個別 clip の分類だけでなく、収集 dataset の構成把握にも有利であった。Nano の MAE 0.084 は、大量一次走査には利用可能であるものの、数 points 単位の分布変化を監視する用途では人手監査または Super による補正が必要であることを示す。

表 19: 予測 positive を優先した希少 scene 人手確認

条件	確認率	P@K	R@K	enrichment
Cosmos3-Nano / adaptive 24-reasoned	1.0	62.2	3.4	3.34
Cosmos3-Nano / adaptive 24-reasoned	5.0	54.8	14.8	2.94
Cosmos3-Nano / adaptive 24-reasoned	10.1	46.9	25.3	2.52
Cosmos3-Nano / adaptive 24-reasoned	20.0	39.9	42.8	2.14
Cosmos3-Nano / uniform 24-reasoned	1.0	60.7	3.3	3.26
Cosmos3-Nano / uniform 24-reasoned	5.0	62.6	16.9	3.36
Cosmos3-Nano / uniform 24-reasoned	10.1	49.9	27.0	2.68
Cosmos3-Nano / uniform 24-reasoned	20.0	41.1	44.1	2.21
Cosmos3-Super / adaptive 24-reasoned	1.0	88.9	4.9	4.77
Cosmos3-Super / adaptive 24-reasoned	5.0	58.0	15.6	3.11
Cosmos3-Super / adaptive 24-reasoned	10.1	53.8	29.0	2.89
Cosmos3-Super / adaptive 24-reasoned	20.0	51.8	55.7	2.78

表19は、予測 positive を先頭へ並べ、人が上位何%を確認するかを変えた結果である。P@K は確認対象の純度、R@K は全希少 scene のうち発見できた割合、enrichment は同数を無作為抽出した場合に対する陽性密度の倍率を表す。確認率を増やすほど R@K は上昇する一方、確信度の低い候補まで含むため P@K と enrichment は低下する。Super の上位 1% は P@K 88.9%、enrichment 4.77 であり、限られた人手予算を高濃度候補へ集中できる。これは active learning による再学習効果そのものではなく、その前段となる候補抽出効率を示す結果である。

8. 考察

8.1 ラベリングの意義

scene label は単なる検索 metadata ではない。第一に、タグ prevalence により収集 dataset の偏りを監視できる。第二に、希少 event 候補を rank し、人手確認を random sampling より集中できる。第三に、model disagreement や低信頼区間を active learning 候補として、downstream perception/planning model の再学習 set へ接続できる。ただし本稿の retrieval 評価は人手確認効率の proxy であり、再学習後の性能向上を直接示すものではない。

8.2 品質と費用の解釈

最良条件は Super / 固定 VO motion prior で、F1 76.2、MCC 0.698 であった。Cosmos3-Nano / adaptive 24-reasoned に対する Cosmos3-Nano / uniform 24-reasoned の paired F1 差は +0.5 points (95% CI: -0.2+1.2)、定常推論費用は 1.0 倍であった。Cosmos3-Nano / uniform 24-reasoned の点推定値は高いが 95% 信頼区間が 0 を跨ぐため、明確な品質優位は確認できない。実装の簡潔性、latency、費用を含めて運用条件を選ぶ必要がある。公開 motion fusion は、公式生 INS/GNSS を使用せず、認証不要の公開派生軌跡と全動画から再計算可能な VO だけで構成した。映像 baseline に対する F1 差の source-video block bootstrap 95% CI は +1.3+2.2 points である。motion prior 自体は追加 GPU request を要さず、閾値は development で固定して evaluation では変更していない。Hybrid Core の Development における baseline 比 F1 差は +3.3 points (95% CI: +1.4+4.5 points) であった。改善は、全タグを長文化することではなく、左折、車線変更、停止車両、横断待ち、二輪車の判定に必要な時系列証拠と反証を明示した結果である。ただし未使用 Evaluation へはまだ適用していないため、Population 性能の上昇としては主張しない。Recall 診断は、Full Run で covered と分類された FN にも、局所時間密度不足、小物体・track 不足、multi-label 競合という複数原因が残ることを示した。Oracle 48 の hard label は 5/14 回復に留まる一方、タグ別 score ではより多くを回復できたため、一律な FPS 増加より candidate routing と tag-specific 判定を組み合わせる方が妥当である。ただし本診断は難例濃縮かつ GT Oracle であり、本番候補生成器の Recall と全体費用は未測定である。開発 split では Uniform 24-frame が最良であったが、evaluation での F1 改善は 0.5 points に留まり、信頼区間も 0 を跨いだ。従って「均等 sampling が常に優れる」とは主張せず、motion peak へ frame を集中する sampling では明確な品質改善が得られなかったという否定的結果を重視する。一方、後述する構造化 VO prior は有意な改善を示した。Uniform は前処理が単純で費用予測も容易であるため、同等品質なら実装上の既定値として合理的である。

frame 数を増やすだけでは性能は単調増加せず、timestamp を提示した上で、全 frame と除外条件を順序立てて照合させる prompt 形式の影響が大きかった。また、FN の 95% 超は event 区間を十分含む入力でも残った。従って、次段階の品質改善は一律な FPS 増加ではなく、小物体 crop、detector/track summary、lane geometry、タグ別の contrastive criteria、および Super による選択的再判定へ配分すべきである。

grouped request は MM/prefix cache を高率に再利用したが、request 数と Decode が増えるため、end-to-end 費用を削減しなかった。cache は「複数回問い合わせる必要が既にある場合」の追加費用を抑える機構であり、cache hit を得るために request を分割すること自体は目的にならない。タグ別では、自車走行 (F1 93.4, positive $n = 701$)、自車停止 (F1 90.7, positive $n = 264$)、対象信号赤 (F1 83.3, positive $n = 226$) が高かった一方、自車車線変更 (F1 15.0, positive $n = 20$)、歩行者横断待ち (F1 28.3, positive $n = 123$)、停止車両 (F1 44.9, positive $n = 272$) が低く、希少 maneuver と歩行者の意図・運動状態には追加の track 情報または局所高 FPS evidence が必要である。

8.3 品質を支配した要因の階層

本実験で観測した改善幅は、すべて同じ種類の変更ではない。Prompt はモデルが既に見ている evidence の照合方法、model 規模は視覚・意味推論能力、VO prior は映像で曖昧な自車状態の外部拘束、Sampling はどの時刻を観測するかに作用する。代表的な差を表 20 に整理する。

表 20: 代表的な変更の効果量と解釈

変更	基準 F1	変更後 F1	解釈
timestamp-only→reasoned prompt (dev)	45.8	70.2	既存 evidence の確認手続が最大の改善要因
Nano adaptive→Super (eval)	68.9	74.5	主に false positive 抑制。model 能力差
Super→固定 VO prior (eval)	74.5	76.2	自車状態だけを構造化運動で補正
Nano adaptive→uniform (eval)	68.9	69.4	小差で CI は 0 を跨ぐ。Sampling 優位は未確定

この順序は、時系列 scene labeling では「より多くの frame を入れる」ことが第一の改善策ではなく、まず判定手続と出力契約を安定させ、次に model 能力、最後に残存誤りへ構造化 context を割り当てる方が効率的であることを示す。ただし、効果量は異なる split と操作因子から得たものであり、相互に加算可能な寄与率を表すものではない。

8.4 生成的 context と決定論的 fusion

自車運動 context を自然言語として Super へ再入力する development 実験では、映像 baseline F1 72.2 に対し、VO context による自車 action 再判定は F1 74.6、27 pairs 改善・8 pairs 悪化であった。一定の効果は確認できたが、動画 Prefill を伴う追加 request が必要であり、context が直接支持しないタグも再生成させると予測が変動する。公開 OPR 軌跡は速度・道路曲率を粗く表す一方、ROAD の「交差点での右左折」と単なる道路湾曲を一意に区別できない。

これに対し固定 VO prior は、変更対象を走行、停止、左折の 3 タグへ限定し、13 タグ全体では 90 pairs 改善・16 pairs 悪化となった。追加 VLM pass を要さず、判断根拠と変更箇所を追跡できる。この結果は、異種 sensor 情報を VLM prompt へ無制限に足すより、各情報源の観測能力を定義し、タグ単位の promotion/veto として融合する方が安定することを示す。特に、粗い yaw から右左折を新規 positive へ promotion するより、視覚 positive を支持しない場合だけ veto する保守的利用が安全である。

8.5 否定的結果から得られた設計知見

本稿では採用しなかった条件も、方式選定上の重要な結果である。

- GT を使わない motion peak 集中は Uniform を明確に上回らなかった。一方、対象を covered FN へ限定した Super の GT Oracle 48 は 5/14 件を回復した。従って局所時間密度は一部に有効だが、全件一律の高 FPS 化を正当化するほど支配的ではない。
- 48-frame 化、multi-scale mosaic、GT-box ROI は回復と悪化が非単調であり、Prefill 費用も増加した。48 frames は Full Run 済みの最終方式ではなく、candidate routing を前提とする選択的 extension として扱う必要がある。
- grouped request は高い MM/prefix cache hit を得たが、3 回分の Decode と scheduler overhead により単一 request より高価であった。cache hit 率は最終目的ではない。
- Chunked Prefill は 24-frame workload で server default c4 を上回らず、c8 は費用最小でも tail latency と Super の preemption を悪化させた。
- 車線変更専用 pass および Map 付き 4 タグ pass は追加費用に対して悪化 pair が多く、Evaluation へ進めなかった。複雑な maneuver には prompt 追加ではなく lane geometry と track の明示が必要である。

このように、複雑さを増す候補は単純 baseline を上回った場合だけ次段階へ進めた。結果として最終方式は、最も多くの component を持つ構成ではなく、効果が再現した component だけを残した構成となった。

8.6 推奨構成

本実験範囲から、実証水準を分けて次の構成を提示する。

- 大量 offline labeling:** Nano、Uniform 3 FPS/24 frames、reasoned single request を用いる。throughput と費用を優先する場合は concurrency 8、tail latency を管理する場合は concurrency 4 とする。
- Evaluation で実証済みの品質優先構成:** Super、Adaptive 24 frames、reasoned single request、concurrency 4 を用いる。公開 VO の固定 motion prior を追加し、F1 76.2 を得た。motion prior は追加 GPU request を要しないが、CPU による VO 前処理費用は GPU 推論費用へ含めていない。PCIe-only TP4 であり、GPU 推論費用は Nano の約 20 倍である。
- 品質・費用の中間:** 全件を Nano で処理し、複雑時系列 positive だけを Super へ送る。本条件では F1 73.4、\$10.01/1,000 clips で、Super 全件の F1 74.5 へ近づいた。
- 次に固定 Evaluation すべき提案 extension:** 一次 pass へ Hybrid Core を用い、detector/tracker 等が強く支持する negative だけを 48-frame・タグ別 YES/NO pass へ送る。これは Development および Oracle 診断に基づく提案であり、76.2% へ上乗せした性能値は本稿では報告しない。

Chunked Prefill は本 workload で server default を上回らなかったため、既定設定を変更する根拠はない。一方、長時間動画や frame budget を増やす場合は Prefill 比率が上昇するため、同じ結論を外挿せず再測定する必要がある。

8.7 運用費用の感度

定常推論だけを線形換算すると、100 万 clips の EC2 費用は Nano \$663、Super \$13485 である。全件を Nano で処理し、予測 positive 等で選んだ上位 5% だけを Super で再判定する場合、費用は \$1.34/1,000 clips、100 万 clips で \$1337 となり、Super 全件適用比で 90.1% 低い。これは費用の感度分析であり、二段構成の最終 F1 を直接測定した結果ではない。model download、compile、idle、storage、network 費用を含まないため、低稼働率では実費が増える。

8.8 再現性と実験妥当性

品質評価は公開 ROAD だけから構成し、source video 単位で development/evaluation を分離した。evaluation 条件は development で固定後に一度だけ適用し、serving Smoke の品質値を Full Run 表へ混入させていない。全 run は入力 media、timestamp、prompt、container digest、vLLM command、pod profile、GPU telemetry および SHA-256 を保存した。表 12 は同一 15 clips に対する各 1 回の探索的計測であり、latency の信頼区間や instance 間変動を推定していない。この制約を越えて小数点以下の差を一般化せず、採否は大きな throughput 差、tail latency および preemption の有無に基づけた。さらに Nano serving の主要 6 条件は pod を再作成して 3 回反復し、平均と標本標準偏差を報告した。これにより、単一 run の一時的な cache 状態や scheduler 揺らぎを一般化する危険を低減した。

8.9 限界

ROAD は英国 Oxford 周辺の限定された camera/domain であり、天候・地域・sensor placement の一般化を保証しない。clip-level 変換は event onset/offset の temporal localization 精度を直接測らない。Hybrid Core は 3 source videos の development で選定され、未使用 evaluation へまだ Full Run していないため、75.6% を母集団性能として扱えない。48-frame 診断は同じ development から意図的に難例を濃縮し、GT event 時刻と GT box を含む上限条件を使用した。従って、診断 P/R/F1、YES-score 閾値、費用 proxy は探索の結果であり、実運用の Precision/Recall や全 clip 費用を表さない。log probability から作った YES score は校正済み確率ではない [9]。閾値も同じ診断集合上で比較したため、独立した calibration split で再固定し、Brier score や ECE 等で校正性を確認する必要がある。また、Hybrid 候補 3 種と全 Contrastive を同一 development で比較しており、多重比較を補正した検定ではない。簡潔性を選択規則へ含めたものの、3 source videos に対する block bootstrap の cluster 数は少なく、CI 自体も粗い。従って Prompt 改善の母集団効果は固定 Evaluation で確認すべきである。希少タグは source video 数が少なく bootstrap CI が広い。Super の速度は PCIe-only 4 GPU 構成の制約を含み、NVLink/NVSwitch 環境の上限性能ではない。これらを越える主張は行わない。

9. 結論

本稿は、公開 ROAD dataset の密な時間注釈から完全な正負 GT を構成し、Cosmos 3 による時系列 scene labeling を品質、計算費用、serving 効率、分布推定および希少 scene 抽出の観点から評価した。正例のみを信用する評価を避け、false positive と abstention を含む confusion matrix、元動画単位 CI、99% coverage gate を導入した点が重要である。結果は、入力 frame 数よりも timestamp を含む判定手順と prompt 構成が品質へ大きく影響し、同一 media を用いる複数 request では cache 再利用により追加費用を抑えられることを示した。Development では、全タグを一律に長文化するより、難しい 5 タグだけへ肯定証拠・時間検査・除外条件を付与する Hybrid Core が、短い baseline に対して F1 を 3.3 points 改善した。また、covered FN を対象とする上限診断では GT event 近傍 48 frames により

5/14 件、タグ別の未校正 YES score では閾値に応じて 7-11/14 件を回復した一方、negative-control FP も 2-5/7 件発生した。この結果から、全件の frame 数を増やすのではなく、外部候補が支持する negative だけへ 48-frame・tag-specific pass を適用する階層方式を提案した。また、ROAD 上の controlled serving 実測から、continuous batching、Chunked Prefill、短い output、同一 media の MM/prefix cache 再利用が、互いに異なる stage へ作用することを確認した。したがって、モデル選択だけでなく、evidence 生成から request scheduling までを一体で設計する必要がある。さらに、静的背景の visual flow と yaw を用いる固定 fusion は、Super 映像 baseline の F1 74.5 を 76.2 へ改善し、frame 追加よりも自車運動の構造化が有効であることを示した。今後は、Hybrid Core と候補駆動 48-frame pass を未使用 evaluation へ固定適用し、detector/tracker が GT Oracle 時刻をどこまで近似できるかを検証する。さらに、異なる地域の公開 dataset、event 境界の temporal mAP、独立 calibration 上の連続 YES score、および実際の downstream 再学習を含む active learning loop で検証する。

参考文献

- [1] G. Singh et al., “ROAD: The ROAD event Awareness Dataset for Autonomous Driving,” *IEEE Trans. Pattern Anal. Mach. Intell.*, 2022, doi:10.1109/TPAMI.2022.3150906.
- [2] W. Maddern et al., “1 Year, 1000 km: The Oxford RobotCar Dataset,” *Int. J. Robotics Research*, 2017.
- [3] NVIDIA et al., “Cosmos 3: Omnimodal World Models for Physical AI,” arXiv:2606.02800, 2026.
- [4] W. Kwon et al., “Efficient Memory Management for Large Language Model Serving with PagedAttention,” in *Proc. ACM SOSP*, 2023.
- [5] J. Lin et al., “Exploring Diversity-based Active Learning for 3D Object Detection in Autonomous Driving,” *IEEE Trans. Intell. Transp. Syst.*, 2024.
- [6] J. Z. Bengar et al., “Temporal Coherence for Active Learning in Videos,” in *Proc. ICCV Workshops*, 2019.
- [7] OPR Project, “OxfordRobotCar OpenPlaceRecognition,” Hugging Face Datasets, CC BY-NC-SA 4.0, accessed Aug. 9, 2026.
- [8] OpenStreetMap contributors, “OpenStreetMap,” Open Data Commons Open Database License (ODbL), fixed snapshot accessed Aug. 9, 2026.
- [9] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On Calibration of Modern Neural Networks,” in *Proc. 34th Int. Conf. Machine Learning*, PMLR 70:1321-1330, 2017.